MATH317 · NUMERICAL METHODS

# Chapter 2 Floating-Point

ملخص الميد · المحاضرة 4

**محارب**

## محتوى الملف


01 ليش الكمبيوتر ما يخزّن كل الأرقام؟

02 Normalized form

03 Single و Double precision

04 التحويل إلى Single precision: سبع خطوات

05 نفس الرقم بالـ Double precision

06 العكس: من Hex إلى عشري

07 Roundoff error

08 كيف يجي في الميد؟

09 أخطاء شائعة

10 اختبر نفسك

## 01 ليش الكمبيوتر ما يخزّن كل الأرقام؟

أنت تكتب الأرقام بالنظام العشري. الكمبيوتر يخزّنها بالنظام الثنائي، وعنده عدد محدود من الـ bits.

المشكلة: فيه أرقام قصيرة بالعشري، لكنها بالثنائي ما تنتهي أبداً.

$$(0.1)_{10} = (0.0\ 0011\ 0011\ 0011\ \ldots)_2$$

**Machine numbers**

الأرقام اللي يقدر الكمبيوتر يخزّنها بالضبط اسمها **Machine numbers**. عددها محدود، وأغلب الأرقام الحقيقية ليست منها.

| المصطلح | معناه |
|---|---|
| **Overflow** | الرقم أكبر من أكبر قيمة يقدر الجهاز يخزّنها. |
| **Underflow** | الرقم أقرب للصفر من أصغر قيمة يقدر الجهاز يخزّنها. |
| **Hole at zero** | الفراغ بين الصفر وأصغر رقم موجب يتخزّن. |

## 02 Normalized form

قبل ما ندخل في الـ bits، نكتب الرقم بشكل واحد ثابت: نحرّك الفاصلة ونسجّل كم خانة حرّكناها.

$$\text{Decimal:}\quad x = \pm\, 0.d_1d_2d_3\ldots \times 10^n \qquad (d_1 \neq 0)$$

$$\text{Example:}\quad 79325 = 0.79325 \times 10^5$$

$$\text{Computer:}\quad x = \pm\, 1.xxxx \times 2^m$$

الجزء `0.79325` اسمه **Mantissa**، والأس `5` اسمه **Exponent**.

**انتبه**

في الاختبار دائماً نحرّك الفاصلة لين يصير قبلها `1` واحد فقط. السلايد يسميها **one-plus form**.

### مثال الجهاز الصغير

السلايد يتخيل جهاز أرقامه بهذا الشكل فقط:

```
x = ± (0.b₁b₂b₃)₂ × 2^(±k)        every bᵢ and k is 0 or 1
```

إذا اشترطنا `b₁ = 1` ، أصغر رقم موجب يصير `(0.100)₂ × 2⁻¹ = 1/4` . ما فيه أي رقم بين `0` و `1/4` ، وهذا هو الـ **Hole at zero**.

## 03 Single و Double precision

### Single precision (32-bit)




```
value = (−1)ˢ × 2^(c − 127) × (1.f)₂
```

### Double precision (64-bit)




```
value = (−1)ˢ × 2^(c − 1023) × (1.f)₂
```

| الخانة | اسمها | وش فيها |
|---|---|---|
| `s` | **Sign** | الإشارة. موجب `0` وسالب `1`. |
| `c` | **Biased exponent** | الأس بعد ما نجمع عليه الـ **Bias**. |
| `f` | **Mantissa** / **Fraction** | الأرقام اللي بعد الفاصلة فقط. الواحد اللي قبلها ما يتخزّن. |

## جدول المقارنة (احفظه)

| | Single | Double |
|---|---|---|
| bits **Exponent** | 8 | 11 |
| bits **Fraction** | 23 | 52 |
| **Bias** | 127 | 1023 |
| أكبر رقم | $\approx 3.4 \times 10^{38}$ | $\approx 1.8 \times 10^{308}$ |
| أصغر رقم موجب | $\approx 1.2 \times 10^{-38}$ | $\approx 2.2 \times 10^{-308}$ |
| **Machine epsilon** | $2^{-23} \approx 1.2 \times 10^{-7}$ | $2^{-52} \approx 2.2 \times 10^{-16}$ |
| خانات الـ Hex في الجواب | 8 | 16 |

**Machine epsilon**

أصغر رقم موجب ε يخلّي `1 + ε` مختلف عن `1` عند الكمبيوتر. هو مقياس دقة الجهاز.

## 04 التحويل إلى Single precision: سبع خطوات

هذا سؤال الشابتر في الاختبار. جاء في الميدات الأربعة اللي راجعتها. نحل مثال السلايد `-52.234375` خطوة خطوة.

### 1 SIGN الإشارة

الرقم سالب، إذن `s = 1` . من الحين نشتغل على `52.234375` .

### 2 INTEGER PART الجزء الصحيح إلى ثنائي

الدكتور يحوّل للنظام الثماني أول، لأن كل خانة ثمانية تساوي 3 bits. نقسم على 8 ونقرأ البواقي من تحت لفوق.

```
52 ÷ 8 = 6    remainder 4
 6 ÷ 8 = 0    remainder 6
```

```
52 = (64)₈          6 → 110       4 → 100
```

```
52 = (110100)₂
```

### 3 الكسر إلى ثنائي FRACTION PART

في الكسر نضرب في 8 وناخذ الجزء الصحيح كل مرة، ونقرأ من فوق لتحت.

```
0.234375 × 8 = 1.875   →  1
```

```
0.875    × 8 = 7.000   →  7
```

```
0.234375 = (0.17)₈        1 → 001        7 → 111
```

```
0.234375 = (0.001111)₂
```

### 4 نحرّك الفاصلة NORMALIZE

```
52.234375 = (110100.001111)₂ = 1.10100001111 × 2⁵
```

حرّكنا الفاصلة 5 خانات لليسار، فالأس `m = 5` .

### 5 نجمع الـ Bias EXPONENT

```
c = 5 + 127 = 132 = (204)₈ = (10000100)₂
```

لازم يكون 8 bits بالضبط.

### 6 نعبّي خانة f FRACTION FIELD

ناخذ اللي بعد الفاصلة فقط، ونكمّل أصفار على اليمين لين يصيرون 23 bit.

```
f = 10100001111 00000000000
```

## 7 HEX نرتّب ونحوّل إلى Hex

```
1 | 10000100 | 10100001111000000000000
```

```
1100 0010 0101 0000 1111 0000 0000 0000
```

```
 C    2    5    0    F    0    0    0
```

$$-52.234375 = [C250F000]_{16}$$

**تأكد من جوابك**

الرقم السالب دائماً يبدأ بحرف من 8 إلى F. وجواب الـ Single دائماً 8 خانات Hex.

## جدول الـ Hex

| Hex | Bits | Hex | Bits | Hex | Bits | Hex | Bits |
|---|---|---|---|---|---|---|---|
| C | 1100 | 8 | 1000 | 4 | 0100 | 0 | 0000 |
| D | 1101 | 9 | 1001 | 5 | 0101 | 1 | 0001 |
| E | 1110 | A | 1010 | 6 | 0110 | 2 | 0010 |
| F | 1111 | B | 1011 | 7 | 0111 | 3 | 0011 |

## 05 نفس الرقم بالـ Double precision

الخطوات من 1 إلى 4 نفسها. يتغيّر: الـ Bias، وعدد bits الأس، وعدد bits الـ f.

```
c = 5 + 1023 = 1028 = (2004)₈ = (10000000100)₂        (11 bits)
```

```
1 | 10000000100 | 10100001111 000...0
```

```
1100 0000 0100 1010 0001 1110 0000 ... 0000
```

```
-52.234375 = [C04A1E0000000000]₁₆
```

**انتبه**

لا تنقل خانات الـ Hex من حل الـ Single. الأس صار 11 bit، فالتقسيم كل 4 يتغيّر كله.

## 06 العكس: من Hex إلى عشري

نفس الخطوات بالمقلوب. مثال السلايد: `[45DE4000]₁₆`

```
 4    5    D    E    4    0    0    0
```

```
0100 0101 1101 1110 0100 0000 0000 0000
```

```
s = 0        c = 10001011 = 139        f = 101111001 000...
```

```
m = 139 − 127 = 12
```

```
value = (1.101111001)₂ × 2¹² = (1101111001000)₂
```

```
      = 4096 + 2048 + 512 + 256 + 128 + 64 + 8
```

```
      = 7112
```

السلايد يحيل حل هذا المثال للكتاب. الحل هنا من عندي وتأكدت منه بالحاسب.

## Roundoff error 07

إذا الرقم ما يكفيه مكان في خانة `f` ، الكمبيوتر يخزّن أقرب **Machine number** له. الفرق اسمه **Roundoff error**.

```
fl(x) = x (1 + δ)        |δ| ≤ u
```

`fl(x)` هو الرقم اللي تخزّن فعلاً. و `u` اسمه **Unit roundoff**: أكبر خطأ نسبي ممكن من تقريب واحد.

| | Single | Double |
|---|---|---|
| (u) **Unit roundoff** | $2^{-24}$ | $2^{-53}$ |
| (ε) **Machine epsilon** | $2^{-23}$ | $2^{-52}$ |

### مثال السلايد

جهاز يحفظ 5 خانات عشرية. نجمع `x = 0.37218 × 10⁴` و `y = 0.71422 × 10⁻¹`.

```
x      = 0.3721800000 × 10⁴
```

```
y      = 0.0000071422 × 10⁴
```

```
x + y = 0.3721871422 × 10⁴
```

```
fl(x + y) = 0.37219 × 10⁴
```

```
relative error = |3721.871422 − 3721.9| / 3721.871422
```

```
               ≈ 7.7 × 10⁻⁶
```

### Loss of significance

إذا طرحنا رقمين متقاربين جداً، تضيع أغلب الخانات الصحيحة ويكبر الخطأ النسبي. هذا اسمه **Loss of significance**.

## 08 كيف يجي في الميد؟

| الميد | الرقم | المطلوب | الجواب |
|---|---|---|---|
| 472 | -23.21875 | Single | C1B9C000 |
| 471 | -45.21875 | Single | C234E000 |
| 461 | 1259.125 | Single | 449D6400 |
| 462 | -184.125 | Double | C067040000000000 |

السؤال عليه 6 إلى 7 درجات، والدرجات موزعة على الخطوات. الدكتور كاتب في نموذج الإجابة أن ترك أي خطوة ينقص الدرجة.

الميدات السابقة تعطيك شكل السؤال، وليست ضمان للميد الجاي.

## 09 أخطاء شائعة

| الخطأ | الصح |
|---|---|
| تكتب الواحد اللي قبل الفاصلة داخل `f` | `f` فيها اللي بعد الفاصلة فقط. |
| تستخدم `127` في سؤال Double | الـ Double له `1023` والأس 11 bit. |
| تنسى الـ Sign bit | ابدأ فيه. السالب `s = 1`. |
| تكتب الأس بأقل من 8 bits | كمّل أصفار على اليسار. مثال: 124 تصير `01111100`. |
| رقم أقل من 1 وتحط الأس موجب | إذا تحركت الفاصلة لليمين، الأس سالب. |

## 10 اختبر نفسك

1. مثّل `85.125` بالـ Single precision.
2. مثّل `-0.15625` بالـ Single precision.
3. مثّل `13.5` بالـ Double precision.
4. وش الرقم العشري المخزّن في `[C1500000]16` ؟

## الحلول

1) $85 = (125)_8 = (1010101)_2$ $\quad .125 = (.1)_8 = (.001)_2$

$1010101.001 = 1.010101001 \times 2^6$

$c = 6 + 127 = 133 = (10000101)_2$

0 | 10000101 | 01010100100000000000000

$= [42AA4000]_{16}$

2) $0.15625 = (.00101)_2 = 1.01 \times 2^{-3}$

$c = -3 + 127 = 124 = (01111100)_2$

1 | 01111100 | 01000000000000000000000

$= [BE200000]_{16}$

3) $13.5 = (1101.1)_2 = 1.1011 \times 2^3$

$c = 3 + 1023 = 1026 = (10000000010)_2$

0 | 10000000010 | 1011 000...0

$= [402B000000000000]_{16}$

4) 1100 0001 0101 0000 ... 0000

s = 1 $\quad$ c = 10000010 = 130 $\quad$ m = 3 $\quad$ f = 101

$value = -(1.101)_2 \times 2^3 = -(1101)_2$

$= -13$

أسئلة اختبر نفسك من إعدادي، وليست من ميدات سابقة.