MATH317 · NUMERICAL METHODS

Chapter 2 Floating-Point

ملخص الميد · المحاضرة 4

محارب

محتوى الملف

01 ليش الكمبيوتر ما يخزّن كل الأرقام؟

02 Normalized form

03 Single و Double precision

04 التحويل إلى Single precision: سبع خطوات

05 نفس الرقم بالـ Double precision

06 العكس: من Hex إلى عشري

07 Roundoff error

08 كيف يجي في الميد؟

09 أخطاء شائعة

10 اختبر نفسك

01 ليش الكمبيوتر ما يخزّن كل الأرقام؟

أنت تكتب الأرقام بالنظام العشري. الكمبيوتر يخزّنها بالنظام الثنائي، وعنده عدد محدود من الـ bits.

المشكلة: فيه أرقام قصيرة بالعشري، لكنها بالثنائي ما تنتهي أبداً.

$$(0.1)_{10} = (0.0\ 0011\ 0011\ 0011\ \ldots)_2$$

Machine numbers

الأرقام اللي يقدر الكمبيوتر يخزّنها بالضبط اسمها **Machine numbers**. عددها محدود، وأغلب الأرقام الحقيقية ليست منها.

المصطلح	معناه
Overflow	الرقم أكبر من أكبر قيمة يقدر الجهاز يخزّنها.
Underflow	الرقم أقرب للصفر من أصغر قيمة يقدر الجهاز يخزّنها.
Hole at zero	الفراغ بين الصفر وأصغر رقم موجب يتخزّن.

02 Normalized form

قبل ما ندخل في الـ bits، نكتب الرقم بشكل واحد ثابت: نحرّك الفاصلة ونسجّل كم خانة حرّكناها.

$$\text{Decimal:}\quad x = \pm\, 0.d_1d_2d_3\ldots \times 10^n \qquad (d_1 \neq 0)$$

$$\text{Example:}\quad 79325 = 0.79325 \times 10^5$$

$$\text{Computer:}\quad x = \pm\, 1.xxxx \times 2^m$$

الجزء `0.79325` اسمه **Mantissa**، والأس `5` اسمه **Exponent**.

انتبه

في الاختبار دائماً نحرّك الفاصلة لين يصير قبلها `1` واحد فقط. السلايد يسميها **one-plus form**.

مثال الجهاز الصغير

السلايد يتخيل جهاز أرقامه بهذا الشكل فقط:

```
x = ± (0.b₁b₂b₃)₂ × 2^(±k)        every bᵢ and k is 0 or 1
```

إذا اشترطنا `b₁ = 1` ، أصغر رقم موجب يصير $(0.100)_2 \times 2^{-1} = \frac{1}{4}$. ما فيه أي رقم بين `0` و $\frac{1}{4}$ ، وهذا هو الـ **Hole at zero**.

03 Single و Double precision

Single precision (32-bit)

s	c	f
1 bit	8 bits	23 bits

```
value = (−1)ˢ × 2^(c − 127) × (1.f)₂
```

Double precision (64-bit)

s	c	f
1 bit	11 bits	52 bits

```
value = (−1)ˢ × 2^(c − 1023) × (1.f)₂
```

الخانة	اسمها	وش فيها
`s`	**Sign**	الإشارة. موجب `0` وسالب `1`.
`c`	**Biased exponent**	الأس بعد ما نجمع عليه الـ **Bias**.
`f`	**Mantissa** / **Fraction**	الأرقام اللي بعد الفاصلة فقط. الواحد اللي قبلها ما يتخزّن.

جدول المقارنة (احفظه)

	Single	Double
bits **Exponent**	8	11
bits **Fraction**	23	52
Bias	127	1023
أكبر رقم	$\approx 3.4 \times 10^{38}$	$\approx 1.8 \times 10^{308}$
أصغر رقم موجب	$\approx 1.2 \times 10^{-38}$	$\approx 2.2 \times 10^{-308}$
Machine epsilon	$2^{-23} \approx 1.2 \times 10^{-7}$	$2^{-52} \approx 2.2 \times 10^{-16}$
خانات الـ Hex في الجواب	8	16

Machine epsilon

أصغر رقم موجب ε يخلّي `1 + ε` مختلف عن `1` عند الكمبيوتر. هو مقياس دقة الجهاز.

04 التحويل إلى Single precision: سبع خطوات

هذا سؤال الشابتر في الاختبار. جاء في الميدات الأربعة اللي راجعتها. نحل مثال السلايد `-52.234375` خطوة خطوة.

1 SIGN الإشارة

الرقم سالب، إذن `s = 1` . من الحين نشتغل على `52.234375` .

2 INTEGER PART الجزء الصحيح إلى ثنائي

الدكتور يحوّل للنظام الثماني أول، لأن كل خانة ثمانية تساوي 3 bits. نقسم على 8 ونقرأ البواقي من تحت لفوق.

```
52 ÷ 8 = 6    remainder 4
 6 ÷ 8 = 0    remainder 6
```

```
52 = (64)₈          6 → 110       4 → 100
```

```
52 = (110100)₂
```

3 الكسر إلى ثنائي FRACTION PART

في الكسر نضرب في 8 وناخذ الجزء الصحيح كل مرة، ونقرأ من فوق لتحت.

```
0.234375 × 8 = 1.875   →  1
```

```
0.875    × 8 = 7.000   →  7
```

```
0.234375 = (0.17)₈        1 → 001        7 → 111
```

```
0.234375 = (0.001111)₂
```

4 نحرّك الفاصلة NORMALIZE

```
52.234375 = (110100.001111)₂ = 1.10100001111 × 2⁵
```

حرّكنا الفاصلة 5 خانات لليسار، فالأس `m = 5` .

5 نجمع الـ Bias EXPONENT

```
c = 5 + 127 = 132 = (204)₈ = (10000100)₂
```

لازم يكون 8 bits بالضبط.

6 نعبّي خانة f FRACTION FIELD

ناخذ اللي بعد الفاصلة فقط، ونكمّل أصفار على اليمين لين يصيرون 23 bit.

```
f = 10100001111 00000000000
```

7 HEX نرتّب ونحوّل إلى Hex

```
1 | 10000100 | 10100001111000000000000
```

```
1100 0010 0101 0000 1111 0000 0000 0000
```

```
 C    2    5    0    F    0    0    0
```

$$-52.234375 = [C250F000]_{16}$$

تأكد من جوابك

الرقم السالب دائماً يبدأ بحرف من 8 إلى F. وجواب الـ Single دائماً 8 خانات Hex.

جدول الـ Hex

Hex	Bits	Hex	Bits	Hex	Bits	Hex	Bits
C	1100	8	1000	4	0100	0	0000
D	1101	9	1001	5	0101	1	0001
E	1110	A	1010	6	0110	2	0010
F	1111	B	1011	7	0111	3	0011

05 نفس الرقم بالـ Double precision

الخطوات من 1 إلى 4 نفسها. يتغيّر: الـ Bias، وعدد bits الأس، وعدد bits الـ f.

```
c = 5 + 1023 = 1028 = (2004)₈ = (10000000100)₂        (11 bits)
```

```
1 | 10000000100 | 10100001111 000...0
```

```
1100 0000 0100 1010 0001 1110 0000 ... 0000
```

```
-52.234375 = [C04A1E0000000000]₁₆
```

انتبه

لا تنقل خانات الـ Hex من حل الـ Single. الأس صار 11 bit، فالتقسيم كل 4 يتغيّر كله.

06 العكس: من Hex إلى عشري

نفس الخطوات بالمقلوب. مثال السلايد: `[45DE4000]₁₆`

```
 4    5    D    E    4    0    0    0
```

```
0100 0101 1101 1110 0100 0000 0000 0000
```

```
s = 0        c = 10001011 = 139        f = 101111001 000...
```

```
m = 139 − 127 = 12
```

```
value = (1.101111001)₂ × 2¹² = (1101111001000)₂
```

```
      = 4096 + 2048 + 512 + 256 + 128 + 64 + 8
```

```
      = 7112
```

السلايد يحيل حل هذا المثال للكتاب. الحل هنا من عندي وتأكدت منه بالحاسب.

07 Roundoff error

إذا الرقم ما يكفيه مكان في خانة `f` ، الكمبيوتر يخزّن أقرب **Machine number** له. الفرق اسمه **Roundoff error**.

$$fl(x) = x\,(1+\delta) \qquad |\delta| \le u$$

`fl(x)` هو الرقم اللي تخزّن فعلاً. و `u` اسمه **Unit roundoff**: أكبر خطأ نسبي ممكن من تقريب واحد.

	Single	Double
(u) **Unit roundoff**	2^{-24}	2^{-53}
(ε) **Machine epsilon**	2^{-23}	2^{-52}

مثال السلايد

جهاز يحفظ 5 خانات عشرية. نجمع $x = 0.37218 \times 10^{4}$ و $y = 0.71422 \times 10^{-1}$.

$$x = 0.3721800000 \times 10^{4}$$

$$y = 0.0000071422 \times 10^{4}$$

$$x + y = 0.3721871422 \times 10^{4}$$

$$fl(x+y) = 0.37219 \times 10^{4}$$

$$\text{relative error} = \frac{|3721.871422 - 3721.9|}{3721.871422}$$

$$\approx 7.7 \times 10^{-6}$$

Loss of significance

إذا طرحنا رقمين متقاربين جداً، تضيع أغلب الخانات الصحيحة ويكبر الخطأ النسبي. هذا اسمه **Loss of significance**.

08 كيف يجي في الميد؟

الميد	الرقم	المطلوب	الجواب
472	-23.21875	Single	C1B9C000
471	-45.21875	Single	C234E000
461	1259.125	Single	449D6400
462	-184.125	Double	C067040000000000

السؤال عليه 6 إلى 7 درجات، والدرجات موزعة على الخطوات. الدكتور كاتب في نموذج الإجابة أن ترك أي خطوة ينقص الدرجة.

الميدات السابقة تعطيك شكل السؤال، وليست ضمان للميد الجاي.

09 أخطاء شائعة

الخطأ	الصح
تكتب الواحد اللي قبل الفاصلة داخل `f`	`f` فيها اللي بعد الفاصلة فقط.
تستخدم `127` في سؤال Double	الـ Double له `1023` والأس 11 bit.
تنسى الـ Sign bit	ابدأ فيه. السالب `s = 1`.
تكتب الأس بأقل من 8 bits	كمّل أصفار على اليسار. مثال: 124 تصير `01111100`.
رقم أقل من 1 وتحط الأس موجب	إذا تحركت الفاصلة لليمين، الأس سالب.

10 اختبر نفسك

1. مثّل `85.125` بالـ Single precision.
2. مثّل `-0.15625` بالـ Single precision.
3. مثّل `13.5` بالـ Double precision.
4. وش الرقم العشري المخزّن في `[C1500000]16` ؟

الحلول

1) $85 = (125)_8 = (1010101)_2$ $\quad .125 = (.1)_8 = (.001)_2$

$1010101.001 = 1.010101001 \times 2^6$

$c = 6 + 127 = 133 = (10000101)_2$

0 | 10000101 | 01010100100000000000000

$= [42AA4000]_{16}$

2) $0.15625 = (.00101)_2 = 1.01 \times 2^{-3}$

$c = -3 + 127 = 124 = (01111100)_2$

1 | 01111100 | 01000000000000000000000

$= [BE200000]_{16}$

3) $13.5 = (1101.1)_2 = 1.1011 \times 2^3$

$c = 3 + 1023 = 1026 = (10000000010)_2$

0 | 10000000010 | 1011 000...0

$= [402B000000000000]_{16}$

4) 1100 0001 0101 0000 ... 0000

s = 1 $\quad$ c = 10000010 = 130 $\quad$ m = 3 $\quad$ f = 101

$value = -(1.101)_2 \times 2^3 = -(1101)_2$

$= -13$

أسئلة اختبر نفسك من إعدادي، وليست من ميدات سابقة.