MATH317 · NUMERICAL METHODS

# Homework 2 الحل

Problems 2.1 · Floating-point

محارب

## 01 4(f): تمثيل 64.37109375

Determine the single-precision and double-precision machine representation of 64.37109375.

نبدأ بهذا لأنه الأسهل: كسره ينتهي.

```
Sign: positive   →   s = 0
```

```
64 = (100)₈ = (1000000)₂
```

```
.37109375 × 8 = 2.96875  →  2
```

```
.96875    × 8 = 7.75     →  7
```

```
.75       × 8 = 6.0      →  6
```

```
.37109375 = (.276)₈ = (.010111110)₂
```

```
64.37109375 = (1000000.01011111)₂ = 1.00000001011111 × 2⁶
```

### Single precision

$c = 6 + 127 = 133 = (10000101)_2$

0 | 10000101 | 00000001011111000000000

0100 0010 1000 0000 1011 1110 0000 0000

$= [4280BE00]_{16}$

### Double precision

$c = 6 + 1023 = 1029 = (10000000101)_2$

0 | 10000000101 | 00000001011111 000...0

0100 0000 0101 0000 0001 0111 1100 0000 ... 0000

$= [405017C000000000]_{16}$

## 02 4(c): تمثيل –9876.54321

Determine the single-precision and double-precision machine representation of −9876.54321.

## 1 الإشارة والجزء الصحيح

```
Negative   →   s = 1
```

```
9876 ÷ 8 = 1234   r 4
```

```
1234 ÷ 8 = 154    r 2
```

```
 154 ÷ 8 = 19     r 2
```

```
  19 ÷ 8 = 2      r 3
```

```
   2 ÷ 8 = 0      r 2
```

$$9876 = (23224)_8 = (10\ 011\ 010\ 010\ 100)_2 = (10011010010100)_2$$

## 2 الكسر (ما ينتهي)

```
.54321 × 8 = 4.34568  →  4
```

```
.34568 × 8 = 2.76544  →  2
```

```
.76544 × 8 = 6.12352  →  6
```

```
.12352 × 8 = 0.98816  →  0
```

```
.98816 × 8 = 7.90528  →  7
```

```
.90528 × 8 = 7.24224  →  7      ...
```

$$.54321 = (.426077...)_8 = (.100\ 010\ 110\ 000\ 111\ 111\ ...)_2$$

الكسر ما ينتهي، فنكتب خانات كفاية ونقرّب عند حد خانة الـ f.

### 3 نحرّك الفاصلة

```
100110100101000.100010110000111111...
```

```
= 1.00110100101001000101100001111111... × 2^13
```

## Single precision

```
c = 13 + 127 = 140 = (10001100)2
```

```
f = first 23 bits = 00110100101001000101100      (next bit is 0, so no round-up)
```

```
1 | 10001100 | 00110100101001000101100
```

```
1100 0110 0001 1010 0101 0010 0010 1100
```

```
= [C61A522C]16
```

## Double precision

```
c = 13 + 1023 = 1036 = (10000001100)2
```

```
f = first 52 bits of the fraction
```

```
1 | 10000001100 | 0011010010100100010110000111111...
```

```
= [C0C34A4587E7C06E]16
```

قيمتي الـ Hex تأكدت منهم بالحاسب. في الـ Double الخانات الأخيرة تعتمد على خانات الكسر البعيدة، فاكتب الطريقة وأول الخانات على الأقل.

## 03 8(c): من Hex إلى عشري

Determine the decimal number that has the machine representation $[494F96A0]_{16}$.

```
 4    9    4    F    9    6    A    0
```

```
0100 1001 0100 1111 1001 0110 1010 0000
```

```
s = 0        c = 10010010 = 146        f = 10011111001011010100000
```

```
m = 146 − 127 = 19
```

$$\text{value} = (1.10011111001011010100000)_2 \times 2^{19}$$

$$= (11001111100101101010)_2$$

$$= 850282$$

## 04 11: أرقام نظام صغير

Enumerate the set of numbers in the floating-point number system that have binary representations of the form $\pm(0.b_1b_2)_2 \times 2^k$, where $k \in \{-1, 0\}$.

الـ mantissa لها أربع قيم ممكنة، والأس له قيمتين:

| $2^0 \times$ | $2^{-1} \times$ | القيمة | $_2(b_1b_2.0)$ |
|---|---|---|---|
| 0 | 0 | 0 | 0.00 |
| 1/4 | 1/8 | 1/4 | 0.01 |
| 1/2 | 1/4 | 1/2 | 0.10 |
| 3/4 | 3/8 | 3/4 | 0.11 |

```
{ 0,  ±1/8,  ±1/4,  ±3/8,  ±1/2,  ±3/4 }
```

المجموع 11 رقم. الرقم `1/4` يطلع مرتين لكنه ينحسب مرة.

## 05 :15 الخطأ في حالة Underflow

In the case of machine underflow, what is the relative error involved in replacing a number x by zero?

```
Relative error = | x − 0 | / | x | = 1
```

```
= 100 %
```

يعني ضاعت كل الخانات الصحيحة، مهما كانت `x` صغيرة.

## 06 :18 متى fl(1 + x) = 1؟

In a five-decimal machine that correctly rounds numbers to the nearest machine number, what real numbers x will have the property fl(1.0 + x) = 1.0?

نشوف أقرب رقمين للواحد في هذا الجهاز (5 خانات):

$$1 = 0.10000 \times 10^{1}$$

$$\text{Next number above:} \quad 0.10001 \times 10^{1} = 1.0001 \qquad (\text{gap} = 10^{-4})$$

$$\text{Next number below:} \quad 0.99999 \times 10^{0} = 0.99999 \qquad (\text{gap} = 10^{-5})$$

`1 + x` يتقرّب للواحد إذا كان أقرب للواحد من جيرانه، يعني داخل نص الفجوة من كل جهة:

$$0.999995 \;<\; 1 + x \;<\; 1.00005$$

$$\mathbf{-0.5 \times 10^{-5} \;<\; x \;<\; 0.5 \times 10^{-4}}$$

عند الطرفين بالضبط النتيجة تعتمد على قاعدة التقريب عند التساوي.

## 07 :21 خطأ تقريب $2^{-1} + 2^{-26}$

(Continuation) What is the relative roundoff error when we round off $2^{-1} + 2^{-26}$ to get the closest machine number?

نفترض Single precision (الـ mantissa فيها 24 bit مع الواحد).

$$x = 2^{-1} + 2^{-26} = 2^{-1}\,(1 + 2^{-25})$$

$$\text{Machine numbers near } 2^{-1} \text{ are spaced } 2^{-1} \times 2^{-23} = 2^{-24} \text{ apart}$$

$$2^{-26} \text{ is less than half of that spacing } (2^{-25}) \quad \rightarrow \quad \text{fl}(x) = 2^{-1}$$

$$\text{Relative error} = |\, x - \text{fl}(x) \,| \;/\; |\, x \,| = 2^{-26} \;/\; (2^{-1} + 2^{-26})$$

$$\mathbf{\approx 2^{-25} \approx 2.98 \times 10^{-8}}$$

السؤال مكتوب عليه Continuation، يعني يكمل سؤال قبله في الكتاب. افترضت Single precision، فتأكد من نص السؤال اللي قبله.

## 08 38: طرح رقمين متقاربين

Consider a computer that uses five-decimal-digit numbers. Show that if x = 0.5321487513 and y = 0.5321304421, then the operation fl(x) − fl(y) involves a large relative error. Compute it.

```
fl(x) = 0.53215          fl(y) = 0.53213
```

```
fl(x) − fl(y) = 0.00002
```

```
Exact:  x − y = 0.0000183092
```

```
Relative error = | 0.0000183092 − 0.00002 | / 0.0000183092
```

```
               = 0.0000016908 / 0.0000183092
```

```
               ≈ 0.092  (about 9.2 %)
```

**ليش الخطأ كبير؟**

كل رقم لحاله تقرّب بخطأ صغير جداً. لكن لما طرحناهم راحت الخانات المتشابهة وبقي الخطأ، فصار 9% من الناتج. هذا هو الـ **Loss of significance**.